

TP 3 - Gestion de l'incertitude avec les réseaux bayésiens

L'objectif de ce TP est de construire un modèle probabiliste permettant de gérer les incertitudes, de façon à répondre à des questions dans le contexte de la génétique. Au cours de ce TP vous utiliserez la bibliothèque Python `pgmpy`, qui permet la manipulation de modèles graphiques probabilistes et des réseaux bayésiens en particulier.

1 Contexte

Les versions mutées du gène GJB2¹ sont l'une des principales causes de déficience auditive chez les nouveau-nés. Chaque personne est porteuse de deux versions du gène, ce qui signifie que chaque personne peut posséder 0, 1 ou 2 copies de la version GJB2 de la déficience auditive.

À moins qu'une personne ait réalisé un test génétique, il est difficile de savoir combien de copies du gène muté possède une personne. Il s'agit d'un « état caché », c-à-d une information qui a un effet qui peut être observé (déficience auditive), mais que nous ne connaissons pas directement. Certaines personnes peuvent en effet avoir 1 ou 2 copies de GJB2 muté, mais ne pas présenter de déficience auditive, tandis que d'autres peuvent n'avoir aucune copie mutée de GJB2, mais présenter une déficience auditive.

Afin d'étudier les risques d'apparition du gène muté chez les membres de différentes familles, nous décidons d'établir des réseaux bayésiens ayant pour variables des paires (G_p, T_p) pour chaque personne p . G_p représente le nombre de gènes mutés (0, 1 ou 2) portés par la personne p . Chaque personne p a également une variable T_p indiquant avec une valeur oui/non si la personne a le trait caractéristique du gène étudié, c-à-d une déficience auditive. Cette variable T_p peut être vue comme dépendante de G_p puisque la probabilité d'avoir une déficience auditive augmente avec le nombre de copies du gène muté. De plus, les relations de parenté permettent de prendre en compte les risques d'apparition liés à l'hérédité génétique, à l'aide des dépendances entre des variables G en relation directe de parenté.

2 Définition des distributions de probabilité

Les distributions de probabilité nécessaires au calcul des probabilités jointes de toutes les variables peuvent être déterminées à l'aide des informations qui suivent.

Quand aucune donnée n'est connue sur les parents d'une personne, la probabilité du nombre de versions mutées du gène de cette personne est donnée par la probabilité *a priori* de la figure 1a. La probabilité d'apparition du trait caractéristique est déterminée en fonction du nombre de versions mutées du gène par le second tableau de la même figure (Fig. 1b). Ces tableaux vous permettent de compléter les fonctions `get_probs_gene_ancestor()` et `get_probs_trait()` du fichier `genetics.py`.

Quand le père et la mère d'une personne sont connues, il est possible de prendre en compte les liens génétiques dans la dépendance entre les variables G (un gène par chromosome). Le gène GJB2 auquel nous nous intéressons ici est porté par la 13^e paire de chromosomes. Chaque enfant hérite d'une copie du gène GJB2 de chacun de ses parents. Si un parent possède deux copies du gène muté, il le transmettra à l'enfant. Si un parent n'a aucune copie du gène muté, il ne transmettra pas le

1. https://fr.wikipedia.org/wiki/Connexine_26

Gene	2	1	0
P(Gene)	0,01	0,03	0,96


(a) Probabilité *a priori* $P(\text{Gene})$

Gene	2	1	0
$P(\text{Trait=vrai} \text{Gene})$	0,65	0,56	0,01
$P(\text{Trait=faux} \text{Gene})$	0,35	0,44	0,99

(b) Probabilité conditionnelle $P(\text{Trait}|\text{Gene})$

FIGURE 1 – Définition des probabilités.

gène muté à l'enfant. La figure 2 présente un exemple de recombinaison de chromosomes à partir de parents porteurs d'une seule version mutée et d'aucune version.

FIGURE 2 – Exemple de recombinaison des chromosomes de la 13^e paire avec un père porteur d'une version mutée du gène GJB2 et une mère saine.

Après qu'un gène soit transmis, il a une certaine probabilité de subir d'autres mutations : il passe d'une version du gène à une autre, c-à-d d'une version entraînant une déficience à une version saine et vice-versa. La probabilité de mutation est fixée à 0,01 dans nos cas d'étude.

Question

1. Afin de déterminer la probabilité conditionnelle $P(G_{\text{enfant}} | G_{\text{père}}, G_{\text{mère}})$, calculer la probabilité que le chromosome hérité d'un des parents (père ou mère) porte exactement 1 version mutée du gène, en connaissant le nombre de versions mutées de ce parent (fonction `get_probs_heredit1()`).

3 Cas d'étude : famille n°1

Votre tâche dorénavant est de définir un réseau bayésien pour faire des déductions sur les membres de la famille décrite dans la figure 3.

Construisez le réseau bayésien associé à la famille, en indiquant les dépendances entre les variables et en réutilisant les fonctions précédemment codées pour définir les distributions de probabilités conditionnelles et *a priori*. Vérifiez ce modèle graphiquement et avec la fonction `check_model()`. Pour vous aider, un exemple de construction du réseau bayésien présenté en cours avec la bibliothèque `pgmpy` vous est donné dans le fichier `bayesnet.py`. N'hésitez pas également à consulter la documentation officielle de cette bibliothèque, notamment les tutoriels : https://pgmpy.org/detailed_notebooks/2.%20Bayesian%20Networks.html.




FIGURE 3 – Famille n°1.

Question

1. En utilisant l'inférence exacte, prédire G pour Paul, en sachant les valeurs des variables T (les personnes ayant une déficience auditive sont indiquées par une étoile dans la figure 3).
2. En utilisant l'inférence exacte, prédire G pour Paul, en sachant en plus que Jessica et Alia ont respectivement 1 et 2 versions défectueuses du gène.
3. Réalisez la dernière prédiction à l'aide d'une inférence approchée par échantillonnage et comparez les résultats obtenus avec ceux de l'inférence exacte.

4 Cas d'étude : famille n°2

Dans cette dernière partie, vous aurez à étudier la famille plus élargie décrite dans la figure 4. Les personnes présentant une déficience auditive sont là aussi indiquées par une étoile.




FIGURE 4 – Famille n°2.

Questions

Définissez un réseau bayésien propre à cette famille, puis répondez aux questions suivantes à l'aide d'une inférence exacte :

1. Prédiction de G pour George d'une part et pour Liliet d'autre part, en sachant les valeurs observées des variables T ,

2. Prédiction de G pour Goerge et Liliet, en sachant en plus que Katherine n'a aucune version défectueuse du gène.

5 Travail à rendre

Déposez par binôme, sur l'espace de cours, votre programme `genetics.py`, ainsi qu'un fichier texte contenant les réponses aux questions.